

Spiegabilità nei Modelli di Machine Learning

Considerazioni Generali

La spiegabilità (o interpretabilità) di un modello di ML è la capacità di comunicare **come e perché** il modello ha fatto una previsione, in modo comprensibile a un essere umano non esperto di ML.

Contrariamente all'intuizione, la spiegabilità **non è un attributo binario**, ma uno spettro con molteplici dimensioni:

Dimensioni della Spiegabilità

1. Trasparenza Intrinseca (Model-Level Interpretability)

- Il modello stesso è trasparente e interpretabile da design
- Es.: coefficienti di regressione lineare, nodi di un albero decisionale
- **Proprietà**: la struttura del modello comunica direttamente come funziona

2. Tracciabilità Locale (Instance-Level Explainability)

- Per una singola previsione, è possibile tracciare **come** il modello ha raggiunto quella conclusione
- Es.: il cammino dalla radice alla foglia in un albero, i features attivati in una rete neurale
- **Proprietà**: ogni previsione è completamente rintracciabile

3. Interpretabilità dei Parametri

- I parametri del modello hanno un significato tangibile e interpretabile
- Es.: il coefficiente β_j in LR significa "aumentare x_j di 1 causa aumento di y di β_j "
- **Proprietà**: la relazione tra parametri e comportamento è evidente

4. Fedeltà alla Logica Umana

- Le spiegazioni riflettono il ragionamento che un umano avrebbe fatto
- Es.: "il cliente ha defaultato perché: reddito basso (decisione umana plausibile) + punteggio di credito basso"
- **Proprietà**: le spiegazioni suonano coerenti dal punto di vista del dominio

Framework di Lipton (2016)

Il lavoro fondamentale "The Mythos of Model Interpretability" di **Ribeiro et al. (2016)** identifica due categorie ortogonali di spiegabilità:

1. Transparency (Trasparenza del Modello)

Quanto trasparente è il **modello stesso**, indipendentemente dalle predizioni:

- **High**: Linear Regression, Logistic Regression, Decision Trees (piccoli)
- **Medium**: Generalized Additive Models, Ensemble Methods (Random Forests)
- **Low**: Neural Networks, SVM, Gradient Boosting complesso

2. Post-hoc Explainability (Spiegabilità Post-Hoc)

Tecniche applicate **dopo il training** per spiegare previsioni di modelli opachi:

- **LIME (Local Interpretable Model-agnostic Explanations)**: approssima il modello localmente con un modello lineare semplice
- **SHAP (SHapley Additive exPlanations)**: assegna ogni output tra le feature usando valori Shapley dalla teoria dei giochi
- **Feature Importance**: quale feature ha più influenzato la previsione

Interazione tra le due:

- Un modello **altamente trasparente** non ha bisogno di post-hoc (spiegazione è diretta)
- Un modello **opaco** usa post-hoc per compensare
- Ideale: trasparenza intrinseca + capacità predittiva

Fattori che Facilitano la Comprensione

Sulla base di ricerca in interpretabilità (Lipton, Molnar, etc.), ci sono **molteplici aspetti** che facilitano la comprensione di una spiegazione:

1. Semplicità e Brevità

- Spiegazioni corte sono preferite a quelle lunghe
- Un numero limitato di cause spieganti (es. 3-5 feature) è più memorizzabile di 10-20
- **Trade-off**: brevità vs completezza; spesso un compromesso è necessario

2. Confronto tra Istanze (Contrastive Explanations)

- "Perché è stata predetta come positiva *questa* istanza rispetto a *quella*?"
- Spiegazione contrastiva è spesso più illuminante che assoluta
- Es.: "il cliente A ha defaultato ma il cliente B no; la differenza principale è il reddito" è più utile che "il cliente A ha reddito basso"
- **Applicazione**: usare nearest neighbors di classe diversa per confronto

3. Selezione di Cause Determinanti

- Non tutte le feature sono uguali; alcune causano la predizione, altre sono correlate ma non causali
- Una spiegazione dovrebbe identificare i **fattori determinanti**, non tutti i fattori

4. Adattamento al Contesto e all'Audience

- La spiegazione deve essere **appropriata al livello di expertise** dell'audience
- Spiegazione a un medico non è la stessa di quella a un paziente
- Spiegazione a un regolatore non è la stessa di quella a un cliente
- **Proprietà**: la qualità di una spiegazione è relativa al contesto

5. Gestione di Feature Anomali o Outlier

- Se una feature ha un valore inusuale, dovrebbe essere segnalato
- Es.: "il cliente ha un'età di 250 anni (anomalia nei dati), quindi la predizione è inaffidabile"
- **Proprietà**: la spiegazione dovrebbe indicare quando il modello è **al di fuori del dominio** di applicazione

6. Feature Support (Copertura Applicativa)

La **generalità** di una previsione può essere quantificata dal **feature support**:

$$\text{Feature Support}_i = \frac{\text{\#istanze nel training con valori simili a } x_i}{\text{\#istanze totali nel training}}$$

Es.: se stiamo predendo per un cliente di 35 anni, e il 70% del training set era tra 30-40 anni, il support è alto (predizione affidabile). Se era il 5%, il support è basso (predizione in zona extrapolazione).

Implicazione: una spiegazione dovrebbe menzionare il support: "questa predizione è affidabile (support = 0.7)" vs "questa predizione è incerta (support = 0.1)"

7. Causalità vs Correlazione

- Una feature può essere **correlata** alla predizione ma non **causale**

- Es.: "il modello predice default perché il cliente è ricco" potrebbe essere spurio se la ricchezza è correlata al credito score, che è il vero driver
- **Proprietà:** la spiegazione ideale identifica la **relazione causale**, non solo quella correlativa
- **Limite:** senza esperimento (es. A/B test), è difficile provare causalità dai dati osservazionali

Applicabilità vs Generalità

Non è il Parametro Più Importante

Una spiegazione che è **applicabile a molti casi** (alta copertura) non è necessariamente la **migliore** spiegazione:

- Una spiegazione generale ("tutti i clienti giovani sono rischiosi") ha alta applicabilità ma è imprecisa
- Una spiegazione specifica ("questo cliente è rischioso a causa della combinazione unica di reddito basso + punteggio di credito basso + storia lavorativa instabile") ha bassa applicabilità ma è molto più informativa

Principio: la qualità di una spiegazione non si misura dalla sua generalità, ma dalla sua **utilità nel contesto specifico**.

Applicazione ai Tre Algoritmi: Matrice Comparativa

Linear Regression (LR)

Dimensione	Valutazione	Note
Transparency	★★★★★ Alta	Coefficienti diretti e interpreti
Tracciabilità Locale	★★★★★ Alta	Calcolo lineare, completamente tracciabile
Interpretabilità Parametri	★★★★★ Alta	β_j = variazione attesa di y per aumento di 1 di x_j
Fedeltà alla Logica Umana	★★★ Media	Relazioni lineari non sempre riflettono ragionamento umano non lineare
Feature Support	★★★★★ Alta	Facile da calcolare: distanza euclidea dai training
Causalità	★★ Bassa	Coefficienti sono correlazionali, non causali
Necessità Post-Hoc	No	Il modello è sufficientemente trasparente

Logistic Regression (LogR)

Dimensione	Valutazione	Note
Transparency	★★★★★ Alta	Coefficienti interpretati, ma con trasformazione moltiplicativa
Tracciabilità Locale	★★★★★ Alta	Calcolo lineare + sigmoid, completamente tracciabile
Interpretabilità Parametri	★★★★ Media	$\exp(\beta_j)$ = fattore moltiplicativo di odds, meno intuitivo di LR
Fedeltà alla Logica Umana	★★★★ Media	Probabilità è intuitiva, ma dipendenza dal contesto (sigmoid non lineare)
Feature Support	★★★★★ Alta	Facile da calcolare
Causalità	★★★ Bassa	Coefficienti sono correlazionali
Necessità Post-Hoc	No	Sufficiente trasparenza, anche se meno immediata di LR

Decision Tree (DT)

Dimensione	Valutazione	Note
Transparency	★★★★ Media (dipen da profondità)	Trasparente per alberi piccoli, complesso per alberi grandi
Tracciabilità Locale	★★★★★ Altissima	Cammino radice-foglia è completamente trasparente
Interpretabilità Parametri	★★★★★ Alta	Split (feature <= threshold) sono diretti e interpretati
Fedeltà alla Logica Umana	★★★★★ Alta	Decisioni sequenziali rispecchiano ragionamento umano
Feature Support	★★★★ Media	Dipende dalla densità dei dati nelle regioni decisionali
Causalità	★★★★ Media	Split non implicano causalità diretta, ma la struttura sequenziale suggerisce dipendenza
Necessità Post-Hoc	Condizionato	Piccoli alberi no; grandi alberi sì (es. SHAP per pesare feature)

Strategie Specifiche di Spiegabilità per Algoritmo

Linear Regression: Spiegabilità Diretta

Metodo principale: Visualizzazione dei Coefficienti + Feature Effect Plot

Spiegazione di y per istanza i :

$$\begin{aligned}y_{\text{hat}} &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \dots + \beta_p \cdot x_p \\&= 2.5 + 0.3 \cdot (\text{Income}) + (-0.15) \cdot (\text{Age}) + \dots \\&= 2.5 + 0.3 \cdot 50000 + (-0.15) \cdot 35 + \dots \\&= 2.5 + 15000 - 5.25 + \dots \\&= 17000\end{aligned}$$

Componenti della spiegazione:

- **Ordine di importanza:** mostrare quale feature contribuisce di più (in valore assoluto)
- **Segno (direzione):** positivo (aumenta predizione) vs negativo (diminuisce)
- **Magnitudo (effect size):** $\beta_j \times x_j$ è l'impatto assoluto

Logistic Regression: Spiegabilità Probabilistica

Metodo principale: Odds Ratio Interpretation + Probability Threshold

Spiegazione di $P(y=1)$ per istanza i :

$$\begin{aligned}\log(\text{odds}) &= \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \dots \\ &= 1.2 + 0.5 \cdot (\text{CreditScore}/100) + (-0.3) \cdot (\text{Age}/10) + \dots\end{aligned}$$

$$\text{Odds} = \exp(\log(\text{odds})) = \dots$$

$$P(y=1) = \text{Odds} / (1 + \text{Odds}) = 0.72$$

Componenti della spiegazione:

- **Probabilità predetta:** "il modello stima una probabilità del 72%"
- **Odds Ratio:** "aumentare il credit score di 100 punti moltiplica gli odds per $\exp(0.5) = 1.65$ (aumento del 65%)"
- **Confidenza:** basata sulla probabilità stessa (più vicina a 0.5, meno sicura; più vicina a 0 o 1, più sicura)

Decision Tree: Spiegabilità Strutturale

Metodo principale: Tracciamento del Cammino + Feature Importance

Spiegazione di previsione per istanza i :

1. Income ≤ 50000 ? SÌ $\rightarrow$ vai a Nodo 2
2. CreditScore ≤ 650 ? SÌ $\rightarrow$ vai a Nodo 4
3. Age ≤ 30 ? NO $\rightarrow$ vai a Nodo 8
4. Foglia: Predizione = "Default" (95% confidenza, 100 campioni)

Feature Importance:

- Income: 0.35
- CreditScore: 0.40
- Age: 0.15
- ... (altri: < 0.05)

Componenti della spiegazione:

- **Cammino decisionale:** sequenza di regole che portano alla foglia
- **Confidenza della foglia:** frazione di campioni della classe predetta nella foglia
- **Feature importance globale:** quanto importante è ogni feature nell'intero albero

Gestione della Multicollinearità e Feature Correlate

Un aspetto raramente discusso ma importante: **come spiegare quando le feature sono correlate?**

Problema

Se Income e Education sono correlate (persone più istruite hanno redditi più alti):

- **LR:** un modello potrebbe usare Income, l'altro Education, entrambi con coefficienti grandi (instabili)
- **DT:** potrebbe preferire Income al primo split, ignorando Education
- **Spiegazione naïve:** "il reddito è il fattore determinante" — potrebbe mascherare che è in realtà l'istruzione

Soluzione

- **Documentare le correlazioni:** "Income è correlato con Education ($r = 0.7$); le spiegazioni basate su Income potrebbero essere sostituite da Education"
- **Feature selection a priori:** scegliere una variabile del gruppo correlato
- **Metodi sparse:** Lasso/Ridge, che azzerano automaticamente feature ridondanti

Considerazioni Etiche e Normative

Oltre alla comprensione tecnica, la spiegabilità ha implicazioni **etiche e legali**:

GDPR Right to Explanation

Le normative come GDPR (EU) e CCPA (USA) richiedono spiegabilità per **decisioni automatizzate** che colpiscono diritti di individui:

- Un rifiuto di un prestito deve essere spiegabile al cliente
- La spiegazione deve essere in linguaggio umano, non jargon tecnico
- Implica una necessità di **trasparenza intrinseca**, non solo post-hoc

Fairness e Bias

La spiegabilità aiuta anche a identificare **bias ingiusti**:

- Es.: se il modello usa Age per denegare un prestito, e Age è proxy per Genere (illegale in molti contesti), la spiegabilità lo rivela
- **Strumento:** spiegazioni contrastive mostrano se il modello discrimina

Raccomandazioni per la Tesi

Sulla base di quanto discusso, suggerimenti per integrare queste considerazioni:

1. **Matrice comparativa:** includi la tabella sopra nei tuoi algoritmi (consente visione d'insieme)
2. **Per ogni algoritmo:** aggiungi una sezione "Spiegabilità Tipica" che descriva:
 - Come è naturalmente spiegabile
 - Quale metodo post-hoc usare se necessario
 - Limitazioni note
3. **Caso di studio:** considera un dataset di esempio (es. credit scoring) e mostra come ogni algoritmo spiega la stessa previsione
4. **Trade-off Interpretabilità-Accuratezza:** esplicita il fatto che algoritmi più interpretabili (LR, DT small) spesso hanno accuratezza minore, e viceversa
5. **Contesto applicativo:** definisci che una spiegazione è "buona" sempre **relative to context and audience** — non esiste una spiegazione universalmente ottimale

Prompt